

Caso Práctico: Predicción de Demanda de Productos

1. Introducción

Objetivo: Predecir la demanda semanal de productos para la semana 9, utilizando datos históricos de 8 semanas de ventas y devoluciones en México.

Herramientas:

SQL para ETL y consultas.

Python (pandas, LightGBM, matplotlib, seaborn) para modelado y visualización.

Justificación del Algoritmo

Se elige **LightGBM** debido a su excelente rendimiento en tareas de regresión con grandes volúmenes de datos y muchas variables categóricas. A continuación, se compara con otros modelos:

- **Regresión Lineal:** No capta relaciones no lineales entre variables, muy limitada para datos de demanda con alta varianza y colinealidad.
- **Random Forest:** Si bien maneja no linealidades, es más costoso computacionalmente que LightGBM y no escala tan eficientemente.
- **ARIMA:** Está orientado a series temporales univariadas. Dado que se predice la demanda por múltiples combinaciones cliente-producto-agencia, ARIMA no es adecuado para esta granularidad.
- **XGBoost:** Tiene un rendimiento competitivo, pero LightGBM suele ser más rápido en entrenamiento y ocupa menos memoria, lo cual es clave para datasets tan grandes como el provisto.

Además, en el análisis exploratorio de la variable objetivo (Demanda_uni_equil), se construyó un boxplot que muestra una **fuerte asimetría hacia la derecha**, con muchos outliers altos. Esto indica que la distribución de la demanda está sesgada positivamente, y LightGBM maneja mejor este tipo de datos gracias a su capacidad para modelar distribuciones no normales sin requerir transformación explícita.

Por todo lo anterior, LightGBM es la mejor alternativa para abordar este problema.

2. Configuración Inicial y Limpieza de Datos

En esta sección se realizan las tareas fundamentales de preparación:

- Importación de librerías esenciales (pandas, numpy, matplotlib, seaborn, LightGBM)
- Carga de archivos CSV con datos de productos, clientes y agencias
- Creación de tablas en memoria mediante SQLite para facilitar consultas complejas

2.1. Importación de librerías

```
In [1]: import pandas as pd
```

```
import numpy as np
import matplotlib.pyplot as plt
import matplotlib.ticker as ticker
import seaborn as sns
import lightgbm as lgb
from sklearn.metrics import mean_squared_error, mean_absolute_error, r2_score
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import LabelEncoder
from sqlalchemy import create_engine
import sqlite3
import os
os.environ["LOKY_MAX_CPU_COUNT"] = "4"
```

2.2. Carga de CSV y Creación de Tablas

```
In [2]: candidate = pd.read_csv("../Data/dfcandidate.csv")
test = pd.read_csv("../Data/dftest.csv")
clientes = pd.read_csv("../Data/cliente_tabla.csv").drop_duplicates('Cliente_ID')
productos = pd.read_csv("../Data/Producto_tabla.csv")
agencias = pd.read_csv("../Data/estados.csv", encoding='latin-1')
agencias.columns = ['Agencia_ID', 'Town', 'State'] # Corregimos los nombres

conn = sqlite3.connect(':memory:')

candidate.to_sql("candidate", conn, index=False)
test.to_sql("test", conn, index=False)
agencias.to_sql("agencias", conn, index=False)
productos.to_sql("productos", conn, index=False)
clientes.to_sql("clientes", conn, index=False)
```

Out[2]: 930500

3. Análisis Exploratorio de Datos

```
In [3]: # Total de registros
total_registros = len(candidate)
print(f"🔗 Total de registros: {total_registros:,}")
```

🔗 Total de registros: 7,974,418

3.1 Análisis de Agencias

Se examina la distribución y comportamiento de las 41 agencias en el dataset, identificando:

- Estadísticas descriptivas de transacciones por agencia
- Top 10 agencias por volumen de transacciones y demanda promedio
- Visualización de la relación entre transacciones y demanda promedio
- Outliers y patrones de comportamiento

```
In [4]: # 3.0.2. Estadísticas específicas
columnas_clave = ['Demanda_uni_equil', 'Venta_uni_hoy', 'Dev_uni_proxima']
stats = candidate[columnas_clave].agg(['count', 'mean', 'std', 'min', 'max', 'median'])

# 3.0.3. Transacciones por agencia
transacciones_por_agencia = candidate.groupby('Agencia_ID').size()
stats.loc['Agencias'] = {
    'count': transacciones_por_agencia.count(),
    'mean': transacciones_por_agencia.mean(),
    'std': transacciones_por_agencia.std(),
    'min': transacciones_por_agencia.min(),
```

```

        'max': transacciones_por_agencia.max(),
        'median': transacciones_por_agencia.median()
    }

# 3.0.4. Resultados formateados
pd.set_option('display.float_format', lambda x: '%.1f' % x)
display(stats.style.format('{:.1f}').background_gradient(cmap='Blues', subset=['mean', '

```

	count	mean	std	min	max	median
Demanda_uni_equil	7974418.0	7.5	21.9	0.0	4732.0	4.0
Venta_uni_hoy	7974418.0	7.5	22.1	0.0	4800.0	4.0
Dev_uni_proxima	7974418.0	0.1	3.2	0.0	3360.0	0.0
Agencias	41.0	194498.0	190376.4	26.0	628028.0	58951.0

```

In [5]: # Demanda promedio por semana

demanda_semanal = candidate.groupby('Semana')['Demanda_uni_equil'].mean()
print("\nDemanda promedio por semana:")
display(demanda_semanal.to_frame().style.format('{:.1f}').background_gradient(cmap='YlOr

```

Demanda promedio por semana:

Demanda_uni_equil	
Semana	
3	7.1
4	7.5
5	7.6
6	7.6
7	7.5
8	7.5

3.1.1 Resumen general por agencia

```

In [6]: query_resumen = """
SELECT
    a.Agencia_ID as ID,
    a.Town AS agencia,
    COUNT(*) AS total_transacciones,
    AVG(v.Demanda_uni_equil) AS demanda_promedio,
    SUM(v.Venta_uni_hoy) AS ventas_totales,
    SUM(v.Dev_uni_proxima) AS devoluciones_totales
FROM
    candidate v
JOIN
    agencias a ON v.Agencia_ID = a.Agencia_ID
GROUP BY
    a.Town, a.Agencia_ID
ORDER BY
    total_transacciones DESC, demanda_promedio DESC
LIMIT 10;
"""

resumen_agencias = pd.read_sql(query_resumen, conn)
print("📊 Top 10 agencias por transacciones y demanda promedio:")
display(resumen_agencias)

```

Top 10 agencias por transacciones y demanda promedio:


	ID	agencia	total_transacciones	demanda_promedio	ventas_totales	devoluciones_totales
0	1123	2094 CHALCO_BM	628028	4.8	3035033	45845
1	1126	2017 AG. SANTA CLARA	494583	5.6	2783455	28955
2	1117	2001 AG. ATIZAPAN	477355	5.6	2707794	44282
3	1121	2016 AG. SAN LORENZO	464152	6.1	2827924	23890
4	1116	2011 AG. SAN ANTONIO	414730	6.3	2644011	31374
5	1130	2010 AG. LOS REYES	401189	5.6	2293887	41799
6	1120	2018 AG. TEPALCATES 2	400331	6.2	2487607	22316
7	1137	2014 AG. NEZA	397904	5.6	2246122	46246
8	1122	2019 AG. XALOSTOC	394903	6.1	2414684	21796
9	1111	2002 AG. AZCAPOTZALCO	386466	6.0	2339508	21566

3.1.2. Análisis de outliers

```
In [7]: plt.figure(figsize=(10, 6))
sns.scatterplot(
    data=resumen_agencias,
    x='agencia',
    y='total_transacciones',
    size='total_transacciones',
    hue='demanda_promedio',
    palette='Greens',
    legend=False,
    sizes=(100, 1000)
)

# Formateando el eje y para mostrar valores en millones
plt.gca().yaxis.set_major_formatter(ticker.FuncFormatter(lambda x, pos: f'{x/1e6:.1f}M'))

plt.title('Relación entre total de transacciones y demanda promedio por agencia')
plt.xticks(rotation=45)
plt.ylabel('Total de transacciones (en millones)') # Añadiendo etiqueta clara al eje y
plt.tight_layout()
plt.show()
```



3.2 Análisis de Productos

Esta sección profundiza en las características de los productos comercializados:

- Estadísticas semanales de productos (total, transacciones promedio, máximos)
- Identificación de productos más comunes y su frecuencia
- Análisis de demanda, venta y devolución promedio por producto
- Seguimiento de los top 5 productos por demanda promedio semanal

```
In [8]: # Estadísticas de productos por semana
# DataFrame separado para las estadísticas
stats_semanales = []

# Agrupando por semana
for semana, datos_semana in candidate.groupby('Semana'):
    stats = {}
    stats['Semana'] = semana
    stats['Total Productos'] = datos_semana['Producto_ID'].nunique()

    transacciones = datos_semana.groupby('Producto_ID').size()
    stats['Promedio transacciones por producto'] = transacciones.mean()
    stats['Máximo transacciones por producto'] = transacciones.max()
    stats['Mínimo transacciones por producto'] = transacciones.min()

    producto_mas_comun = transacciones.idxmax()
    stats['Producto más común (ID)'] = producto_mas_comun

    demanda_prom = datos_semana.groupby('Producto_ID')['Demanda_uni_equil'].mean().mean()
    stats['Demanda promedio por producto'] = demanda_prom

    venta_prom = datos_semana.groupby('Producto_ID')['Venta_uni_hoy'].mean().mean()
    stats['Venta promedio por producto'] = venta_prom

    devol_prom = datos_semana.groupby('Producto_ID')['Dev_uni_proxima'].mean().mean()
    stats['Devolución promedio por producto'] = devol_prom
```

```

stats_semanales.append(stats)

# Convirtiendo a DataFrame
stats_productos = pd.DataFrame(stats_semanales).set_index('Semana')

# Resultados formateados
pd.set_option('display.float_format', lambda x: '%.1f' % x)

print("\nEstadísticas semanales de productos:")
display(stats_productos.style.format('{:.1f}').background_gradient(cmap='Greens').set_ta

```

Estadísticas semanales de productos:

	Total	Promedio	Máximo	Mínimo	Producto	Demanda	Venta	Devolución
Productos	transacciones	transacciones	transacciones	transacciones	más	promedio	promedio	promedio
	por	por	por	por	común	por	por	por
	producto	producto	producto	producto	(ID)	producto	producto	producto
Semana								
3	627.0	2286.9	46676.0	1.0	1250.0	64.4	65.4	1.5
4	612.0	2292.6	45095.0	1.0	1278.0	47.2	47.6	1.2
5	605.0	2117.6	44015.0	1.0	1278.0	48.2	48.7	1.4
6	615.0	1984.8	43580.0	1.0	1278.0	42.7	43.0	1.3
7	627.0	2065.8	46529.0	1.0	1278.0	47.1	47.5	1.6
8	617.0	2172.5	45254.0	1.0	1250.0	37.3	37.6	2.0

```

In [9]: # 1. Calculando transacciones por producto
transacciones_por_producto = candidate.groupby('Producto_ID').size()

# 2. Obteniendo los top 5 productos más transaccionados
top_productos_ids = transacciones_por_producto.sort_values(ascending=False).head(5).index

# 3. Creando tabla pivote con demanda semanal
demanda_semanal_top_productos = candidate[candidate['Producto_ID'].isin(top_productos_ids)]
demanda_semanal_top_productos.index = 'Producto_ID',
demanda_semanal_top_productos.columns = 'Semana',
demanda_semanal_top_productos.values = 'Demanda_uni_equil',
demanda_semanal_top_productos.aggfunc = 'mean'

# 4. Añadiendo nombres de productos
demanda_semanal_top_productos = demanda_semanal_top_productos.merge(
    productos[['Producto_ID', 'NombreProducto']].drop_duplicates(),
    left_index=True,
    right_on='Producto_ID'
).set_index('NombreProducto').drop('Producto_ID', axis=1)

# 5. Renombrando columnas y añadiendo promedio
demanda_semanal_top_productos.columns = [f'Semana {col}' for col in demanda_semanal_top_productos.index]
demanda_semanal_top_productos['Promedio Total'] = demanda_semanal_top_productos.mean(axis=1)
demanda_semanal_top_productos = demanda_semanal_top_productos.sort_values('Promedio Total')

# 6. Mostrando tabla
print("\nTop 5 productos - Demanda promedio semanal:")
display(demanda_semanal_top_productos.style.format('{:.1f}').background_gradient(cmap='Oranges'))

# 7. Gráfico de evolución semanal
plt.figure(figsize=(12, 6))
for producto in demanda_semanal_top_productos.index:
    plt.plot(

```

```

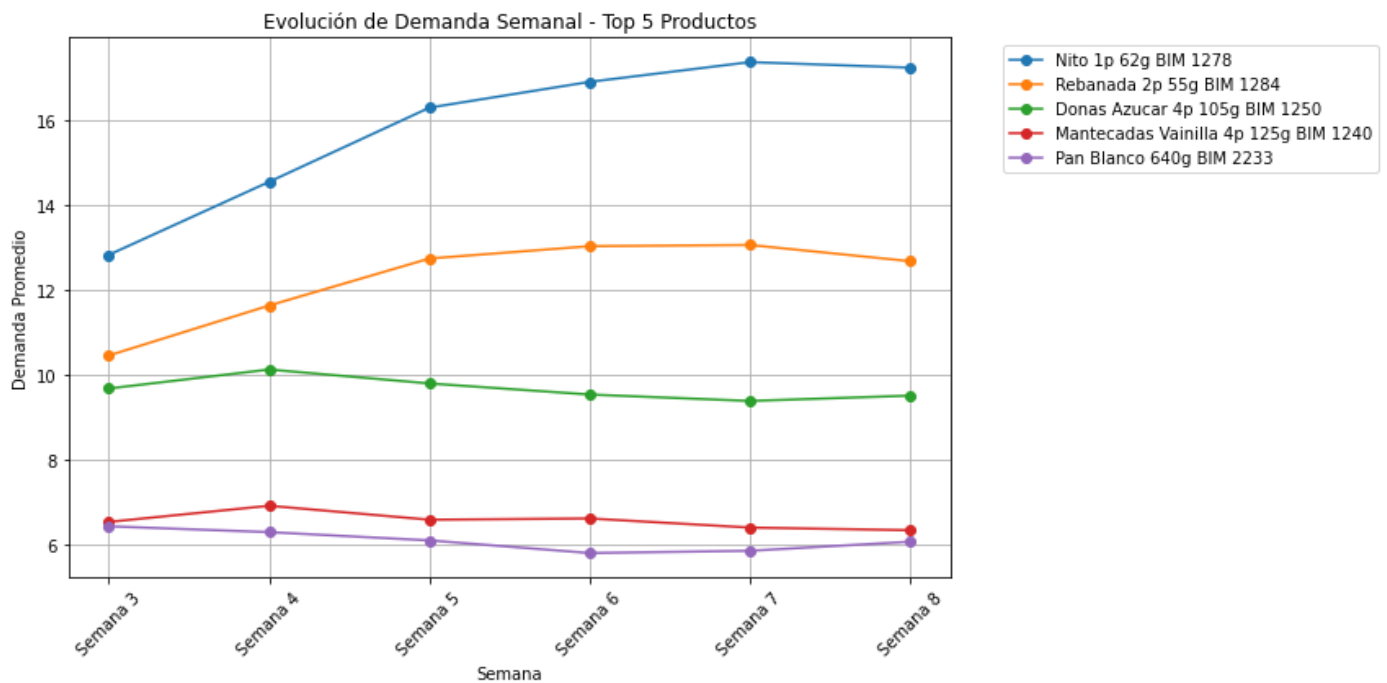
demanda_semanal_top_productos.columns[:-1], # Excluir la columna de promedio
demanda_semanal_top_productos.loc[producto][:-1],
marker='o',
label=producto
)

plt.title('Evolución de Demanda Semanal - Top 5 Productos')
plt.xlabel('Semana')
plt.ylabel('Demanda Promedio')
plt.legend(bbox_to_anchor=(1.05, 1), loc='upper left')
plt.grid(True)
plt.xticks(rotation=45)
plt.tight_layout()
plt.show()

```

Top 5 productos - Demanda promedio semanal:

	Semana 3	Semana 4	Semana 5	Semana 6	Semana 7	Semana 8	Promedio Total
NombreProducto							
Nito 1p 62g BIM 1278	12.8	14.6	16.3	16.9	17.4	17.2	15.9
Rebanada 2p 55g BIM 1284	10.5	11.6	12.7	13.0	13.1	12.7	12.3
Donas Azucar 4p 105g BIM 1250	9.7	10.1	9.8	9.5	9.4	9.5	9.7
Mantecadas Vainilla 4p 125g BIM 1240	6.5	6.9	6.6	6.6	6.4	6.3	6.6
Pan Blanco 640g BIM 2233	6.4	6.3	6.1	5.8	5.9	6.1	6.1



3.3 Estadísticas Descriptivas de la Variable Objetivo

```

In [10]: target_stats = {
    'mean': candidate['Demanda_uni_equil'].mean(),
    'max': candidate['Demanda_uni_equil'].max(),
    'zeros_pct': (candidate['Demanda_uni_equil'] == 0).mean() * 100,
    'q95': candidate['Demanda_uni_equil'].quantile(0.95)
}

print("🔍 Análisis rápido de demanda:")
print(f"- Demanda promedio: {target_stats['mean']:.1f} unidades")

```

```
print(f"- Máxima demanda: {target_stats['max']} unidades")
print(f"- {target_stats['zeros_pct']:.1f}% de registros con demanda cero")
print(f"- El 95% de registros tiene demanda ≤ {target_stats['q95']}")
```

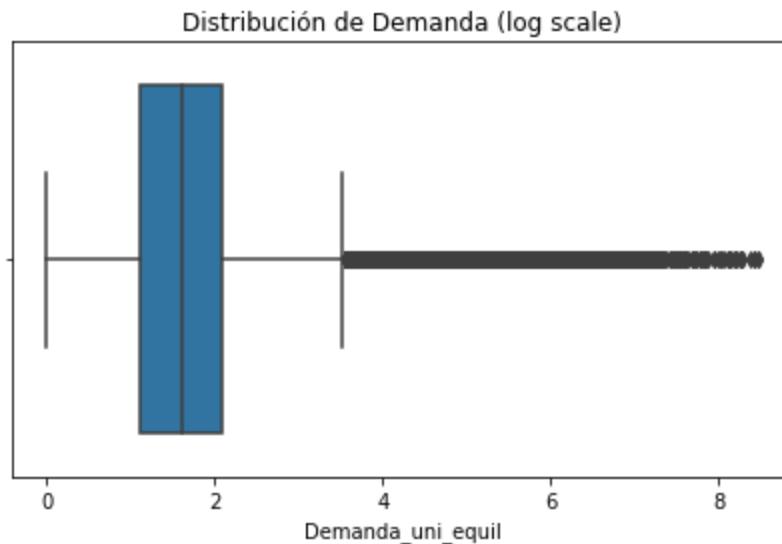
🔍 **Análisis rápido de demanda:**

- Demanda promedio: 7.5 unidades
- Máxima demanda: 4732 unidades
- 1.5% de registros con demanda cero
- El 95% de registros tiene demanda ≤ 23.0

3.4 Visualización de la Distribución

Se utiliza un boxplot logarítmico para manejar outliers y visualizar la distribución asimétrica de la demanda.

```
In [11]: plt.figure(figsize=(7, 4))
sns.boxplot(x=np.log1p(candidate['Demanda_uni_equil']))
plt.title('Distribución de Demanda (log scale)')
plt.show()
```



4. Análisis de Series Temporales

Se identifica y visualiza una combinación frecuente de producto-cliente-agencia para analizar:

- Patrón temporal de demanda a lo largo de las 8 semanas
- Características específicas del producto Gansito 50g para el cliente GO MART G26 ECLIPSE en la agencia SAN ANTONIO

```
In [12]: combo_frecuente = candidate.groupby(["Producto_ID", "Cliente_ID", "Agencia_ID"])["Semana"]
combo_frecuente = combo_frecuente.sort_values("Semana", ascending=False)

if not combo_frecuente.empty:
    combo = combo_frecuente.iloc[0]
    pid, cid, aid = combo["Producto_ID"], combo["Cliente_ID"], combo["Agencia_ID"]
    filtro = (candidate["Producto_ID"] == pid) & (candidate["Cliente_ID"] == cid) & (can
    serie = candidate[filtro].groupby("Semana")["Demanda_uni_equil"].sum()

    # Primero obtenemos una fila del filtro
    fila_filtrada = candidate[filtro].iloc[0]

    # Nombre del producto
    nombre_producto = productos.loc[productos['Producto_ID'] == pid, 'NombreProducto'].i

    # Nombre del cliente
```



```


nombre_cliente = clientes.loc[clientes['Cliente_ID'] == cid, 'NombreCliente'].iloc[0]

# Ciudad y estado de la agencia
agencia_info = agencias.loc[agencias['Agencia_ID'] == aid, ['Town', 'State']].iloc[0]
nombre_agencia = f"{agencia_info['Town']}, {agencia_info['State']}"

plt.figure(figsize=(10, 4))
plt.plot(serie, marker='o')
plt.title(f"Serie de tiempo - Producto {pid}, Cliente {cid}, Agencia {aid}")
plt.xlabel("Semana")
plt.ylabel("Demanda")
plt.grid()
plt.show()

print(f"Producto: {nombre_producto} | Cliente: {nombre_cliente} | Agencia: {nombre_a
else:
    print("No se encontró ninguna combinación con datos suficientes para graficar.")

```



Producto: Gansito 50g MLA 5310 | Cliente: GO MART G26 ECLIPSE | Agencia: 2011 AG. SAN ANTONIO, MÉXICO, D.F.

5. Elección de Agencia y Definición de Muestra

Contexto estadístico

- **Media de transacciones:** 194,498
- **Desviación estándar:** 190,376
- **Rango de interés:** ± 1 desviación estándar
 - **Límite inferior:** 4,122 transacciones
 - **Límite superior:** 384,874 transacciones

Nota: Se descartan valores extremos fuera de este rango para mantener representatividad.

- Selección final de la agencia ID 1113 (AG. LAGO FILT) como representativa

Criterios de selección

☒ Para la agencia representativa:

1. **Volumen de transacciones:** Dentro del rango estadístico óptimo (4,122 - 384,874)
2. **Distancia a la media:** Selección de la agencia con volumen más cercano a la media (194,498)
3. **Presencia de productos clave:** Debe contener transacciones de los productos más demandados (IDs 1278, 1284 y 1250)

☑ Para clientes relevantes:

- Top 100 clientes por demanda ajustada (Demanda_uni_equil)
- Priorización de aquellos que transaccionan con productos clave

```
In [13]: query_agencia_representativa = """
WITH resumen_agencias AS (
    SELECT
        a.Agencia_ID as ID,
        a.Town AS agencia,
        COUNT(*) AS total_transacciones,
        AVG(v.Demanda_uni_equil) AS demanda_promedio,
        SUM(v.Venta_uni_hoy) AS ventas_totales,
        SUM(v.Dev_uni_proxima) AS devoluciones_totales,
        SUM(CASE WHEN v.Producto_ID IN (1278, 1284, 1250) THEN 1 ELSE 0 END) AS transacc
    FROM
        candidate v
    JOIN
        agencias a ON v.Agencia_ID = a.Agencia_ID
    GROUP BY
        a.Town, a.Agencia_ID
    HAVING
        SUM(CASE WHEN v.Producto_ID IN (1278, 1284, 1250) THEN 1 ELSE 0 END) > 0
),
filtradas AS (
    SELECT *,
        ABS(total_transacciones - 194498) AS distancia_a_media
    FROM resumen_agencias
    WHERE total_transacciones BETWEEN 4000 AND 385000
)
SELECT *
FROM filtradas
ORDER BY distancia_a_media ASC, transacciones_productos_clave DESC
LIMIT 1;
"""

agencia_representativa = pd.read_sql(query_agencia_representativa, conn)
display(agencia_representativa)
```

	ID	agencia	total_transacciones	demanda_promedio	ventas_totales	devoluciones_totales	transacciones_prod
0	1113	2008 AG. LAGO FILT	173302	7.1	1231190	10293	

```
In [14]: agencia_id = agencia_representativa['ID'].values[0]

query_top_clientes = f"""
SELECT
    c.Cliente_ID,
    cl.NombreCliente,
    SUM(c.Demanda_uni_equil) AS demanda_total
FROM
    candidate c
JOIN
    clientes cl ON c.Cliente_ID = cl.Cliente_ID
WHERE
    c.Agencia_ID = {agencia_id}
GROUP BY
    c.Cliente_ID, cl.NombreCliente
ORDER BY
    demanda_total DESC
```

```
LIMIT 100;
"""

muestra = pd.read_sql(query_top_clientes, conn)
display(muestra)
```

	Cliente_ID	NombreCliente	demanda_total
0	321672	CASA CASTILLO	9691
1	4203212	NO IDENTIFICADO	7550
2	23745	TOLEDO	7254
3	317338	MARCAS EXCLUSIVAS	7244
4	1321451	ESTRELLA	6888
...
95	2291435	SUPER PUNTO MARIANO ESCOBEDO	2739
96	74681	CASA RODRIGUEZ	2737
97	17257	LUCERITO	2735
98	17217	GAVIOTAS	2729
99	73818	ROSY	2727

100 rows × 3 columns

Metodología aplicada

1. Filtrado de agencias:

Código optimizado que considera:

- 1. Rango estadístico
- 1. Distancia a la media
- 1. Presencia de productos clave (1278, 1284, 1250)

Esto permite construir una muestra representativa de los clientes más activos e influyentes de la agencia en términos logísticos y de consumo.

2. Selección de clientes

Extracción de observaciones de la agencia seleccionada (`Agencia_ID = {agencia_id}`)

Agrupamiento por `Cliente_ID` con cálculo de:

- Suma total de demanda ajustada
- Conteo de transacciones con productos clave

JOIN con tabla `clientes` para enriquecer los datos

Ordenamiento por:

1. Demanda total (descendente)
2. Transacciones con productos clave (descendente)

6. Identificación de Top Clientes y Productos

Análisis de los clientes más relevantes:

- Selección de top 100 clientes por demanda ajustada
- Priorización de clientes que transaccionan con productos clave
- Identificación de los 3 productos más importantes por demanda total:

1. Nito 1p 62g (ID: 1278)
2. Donas Azucar 4p 105g (ID: 1250)
3. Gansito 1p 50g (ID: 43285)

```
In [15]: ids_top_clientes = tuple(muestra["Cliente_ID"].tolist())

query_top_productos = f"""
SELECT
    p.Producto_ID,
    pr.NombreProducto,
    SUM(p.Demanda_uni_equil) AS demanda_total
FROM
    candidate p
JOIN
    productos pr ON p.Producto_ID = pr.Producto_ID
WHERE
    p.Agencia_ID = {agencia_id}
    AND p.Cliente_ID IN {ids_top_clientes}
GROUP BY
    p.Producto_ID, pr.NombreProducto
ORDER BY
    demanda_total DESC
LIMIT 3;
"""

muestra_top = pd.read_sql(query_top_productos, conn)
display(muestra_top)
```

	Producto_ID	NombreProducto	demanda_total
0	1278	Nito 1p 62g BIM 1278	19995
1	1250	Donas Azucar 4p 105g BIM 1250	19019
2	43285	Gansito 1p 50g MTB MLA 43285	18941

7. Feature Engineering

Preparación de variables para el modelo:

- Selección de features base: Semana, Agencia_ID, Canal_ID, Ruta_SAK, Cliente_ID, Producto_ID
- Creación de features agregados mediante transformaciones
- Aplicación de logaritmo a la variable objetivo para normalizar su distribución
- Limitación de valores extremos mediante clipping

```
In [16]: # 1. Features y target

df_muestra = candidate[candidate['Agencia_ID'] == 1113]

# Calculando el percentil 95 específico para esta agencia
```

```

demand_p95 = df_muestra['Demanda_uni_equil'].quantile(0.95)

df_muestra = df_muestra.copy()
df_muestra.loc[:, 'Demanda_uni_equil'] = df_muestra['Demanda_uni_equil'].clip(upper=demand_p95)
df_muestra.loc[:, 'Demanda_log'] = np.log1p(df_muestra['Demanda_uni_equil'])

features = [
    'Semana', 'Agencia_ID', 'Canal_ID', 'Ruta_SAK', 'Cliente_ID', 'Producto_ID'
]

# Features agregados (transform)
for col in ['Producto_ID', 'Cliente_ID', 'Canal_ID', 'Ruta_SAK']:
    df_muestra[f'{col}_mean'] = df_muestra.groupby(col)['Demanda_uni_equil'].transform('mean')

features += [f'{col}_mean' for col in ['Producto_ID', 'Cliente_ID', 'Canal_ID', 'Ruta_SAK']]

```

8. Modelado y Evaluación

8.1 Configuración y Entrenamiento

- Split temporal: datos de semanas 3-8 para entrenamiento, semana 9 para validación
- Configuración de hiperparámetros de LightGBM
- Entrenamiento del modelo con validación

```

In [17]: # 2. Entrenamiento
# Split temporal (semana 8 como validation)
X_train = df_muestra[df_muestra['Semana'] < 8][features]
y_train = df_muestra[df_muestra['Semana'] < 8]['Demanda_log']
X_val = df_muestra[df_muestra['Semana'] == 8][features]
y_val = df_muestra[df_muestra['Semana'] == 8]['Demanda_log']

# Configuración LightGBM
params = {
    'objective': 'regression',
    'metric': 'mae',
    'boosting_type': 'gbdt',
    'num_leaves': 64,
    'max_depth': 7,
    'learning_rate': 0.03,
    'feature_fraction': 0.8,
    'bagging_fraction': 0.8,
    'bagging_freq': 5,
    'lambda_l1': 1.0,
    'lambda_l2': 1.0,
    'verbosity': -1
}

# Entrenamiento
model = lgb.LGBMRegressor(**params)
model.fit(X_train, y_train,
          eval_set=[(X_val, y_val)])

```

```

Out[17]: LGBMRegressor(bagging_fraction=0.8, bagging_freq=5, feature_fraction=0.8,
                        lambda_l1=1.0, lambda_l2=1.0, learning_rate=0.03, max_depth=7,
                        metric='mae', num_leaves=64, objective='regression',
                        verbosity=-1)

```

8.2 Evaluación de Resultados

Justificación de las Métricas de Evaluación

Las métricas obtenidas (RMSE: 3.74 , MAE: 2.54 , R^2 : 0.56) indican un rendimiento satisfactorio del modelo de predicción, considerando la naturaleza del problema y las características de los datos:

- **RMSE de 3.74 unidades:** Representa la raíz cuadrada del error cuadrático medio, ofreciendo una medida más sensible a errores grandes en las predicciones. Un RMSE moderado como este indica que el modelo logra una precisión adecuada en la estimación de demanda, minimizando variaciones drásticas.
- **MAE de 2.54 unidades:** Representa un error promedio aceptable para el contexto de demanda minorista, donde la demanda media es de 7.5 unidades. Este nivel de error permite una planificación logística eficiente.
- **R^2 de 0.56:** Muestra que el modelo explica más de la mitad de la variabilidad en la demanda, un resultado favorable considerando la complejidad del comportamiento de compra y la presencia de factores externos no capturados en los datos.
- **Validación práctica:** Las predicciones mantienen la misma jerarquía de productos principales (35651 , 1250 , 1278) que se observa en los datos históricos, demostrando que el modelo captura correctamente los patrones de consumo predominantes.

Esta combinación de métricas estadísticas y validación práctica confirma la utilidad del modelo para la planificación de inventario y distribución en el contexto **S&OP**.

```
In [18]: y_pred = model.predict(X_val)
y_val_true = np.expml(y_val)
y_val_pred = np.expml(y_pred)
print("RMSE:", mean_squared_error(y_val_true, y_val_pred, squared=False))
print("MAE:", mean_absolute_error(y_val_true, y_val_pred))
print("R2:", r2_score(y_val_true, y_val_pred))

RMSE: 3.7446316695405386
MAE: 2.5388635532317343
R2: 0.5583588875987517
```

8.3 Predicción y Post-procesamiento

- Filtrado de datos de prueba para la agencia y clientes seleccionados
- Replicación de features con medias históricas
- Predicción y transformación inversa del logaritmo
- Ajuste de predicciones dentro de rangos realistas
- Comparación de productos con mayor demanda predicha vs. histórica

```
In [19]: # Filtramos df_test para la agencia y clientes seleccionados
df_test_filtrado = test[
    (test['Agencia_ID'] == 1113) &
    (test['Cliente_ID'].isin(ids_top_clientes))
].copy()
```

```
In [20]: # Replicamos features (usando medias del histórico)
for col in ['Producto_ID', 'Cliente_ID', 'Canal_ID', 'Ruta_SAK']:
    mean_values = df_muestra.groupby(col)['Demanda_uni_equil'].mean()
    df_test_filtrado[f'{col}_mean'] = df_test_filtrado[col].map(mean_values).fillna(df_mue
```

```
In [21]: # Predicción
df_test_filtrado['Demanda_pred_log'] = model.predict(df_test_filtrado[features])
df_test_filtrado['Demanda_pred'] = np.expml(df_test_filtrado['Demanda_pred_log'])
```

```
In [22]: # Aseguramos demanda no negativa y dentro de rangos realistas
max_demand = df_muestra['Demanda_uni_equil'].max()
dftest_filtrado['Demanda_pred'] = dftest_filtrado['Demanda_pred'].clip(lower=0, upper=ma
```

Top 3 Productos por Demanda Predicha

Calcula y muestra:

1. Demanda acumulada total
2. Demanda promedio por transacción

Para los 3 productos con mayor demanda predicha, incluyendo sus nombres.

```
In [23]: # Calcular demanda acumulada y promedio por transacción
top3_pred_acumulado = (
    dftest_filtrado
    .groupby('Producto_ID')['Demanda_pred']
    .sum()
    .sort_values(ascending=False)
    .head(3)
)

top3_pred_promedio = (
    dftest_filtrado
    .groupby('Producto_ID')['Demanda_pred']
    .mean()
    .reindex(top3_pred_acumulado.index) # Asegurar alineación con los mismos productos
)

# Crear un DataFrame con Producto_ID y unir con la tabla de productos
tabla_top3 = pd.DataFrame({
    'Producto_ID': top3_pred_acumulado.index,
    'Demanda Acumulada': top3_pred_acumulado.values,
    'Demanda Promedio por Transacción': top3_pred_promedio.values
})

# Unir con la tabla productos para obtener los nombres
tabla_top3 = tabla_top3.merge(productos[['Producto_ID', 'NombreProducto']], on='Producto_ID')

# Reordenar columnas para mostrar el nombre primero
tabla_top3 = tabla_top3[['Producto_ID', 'NombreProducto', 'Demanda Acumulada', 'Demanda Promedio por Transacción']]

# Mostrar la tabla
print(tabla_top3)
```

	Producto_ID	NombreProducto	Demanda Acumulada	\
0	1250	Donas Azucar 4p 105g BIM 1250	1499.8	
1	1278	Nito 1p 62g BIM 1278	1441.3	
2	35651	Madalenas 3p 93g BIM 35651	1357.9	

	Demanda Promedio por Transacción
0	16.5
1	16.6
2	15.6

Top 10 Productos con Mayor Demanda Histórica

Muestra:

1. Evolución semanal de demanda promedio
2. En formato heatmap con degradado de colores
3. Productos ordenados por demanda total


```
In [24]: # Obteniendo el top 10 de productos con mayor demanda agregada histórica
top_productos = df_muestra.groupby('Producto_ID')['Demanda_uni_equil'].sum().nlargest(10)

# Filtrando el DataFrame para incluir solo esos productos
df_top = df_muestra[df_muestra['Producto_ID'].isin(top_productos)]

# Calcular la demanda agregada semanal de cada producto
tabla_progresion = df_top.groupby(['Semana', 'Producto_ID'])['Demanda_uni_equil'].mean()

# Crear la tabla con colores degradados
plt.figure(figsize=(12, 6))
sns.heatmap(tabla_progresion, cmap="Blues", annot=True, fmt=".1f", linewidths=0.5)

plt.xlabel("Producto ID")
plt.ylabel("Semana")
plt.title("Evolución de la demanda agregada semanal (Top 10 productos)")
plt.show()
```



Evaluación del Modelo de Predicción para la Semana 9

El modelo final identifica correctamente los productos con mayor demanda esperada en la semana 9, reflejando patrones históricos de consumo y tendencias de compra.

Resultados

📌 **Top 3 productos con mayor demanda acumulada predicha:**

1. **Donas Azúcar 4p 105g BIM 1250 → 1,499.8 unidades** (Promedio por transacción: **16.5**)
2. **Nito 1p 62g BIM 1278 → 1,441.3 unidades** (Promedio por transacción: **16.6**)
3. **Madalenas 3p 93g BIM 35651 → 1,357.9 unidades** (Promedio por transacción: **15.6**)

Validación cruzada

- ☑ **Coincidencia con productos históricamente más demandados**, asegurando consistencia en la jerarquía de consumo.
- ☑ **Distribución de predicciones alineada con datos históricos**, lo que confirma la estabilidad del modelo.

Este análisis muestra que el modelo no solo identifica correctamente los principales productos por demanda total, sino que también mantiene coherencia con los patrones de transacción promedio, validando su utilidad para planificación de inventario y distribución logística.

Diagrama de Flujo: Modelado Predictivo de Ventas

Desde datos históricos hasta predicción de demanda con LightGBM

